

SUJET D'EXAMEN

Concevoir & Implémenter une Solution d'Intelligence Artificielle *Cas d'usage : IA de Planification Personnalisée de Séjours et Voyages*

1. Contexte général

Une agence de voyages haut de gamme souhaite développer une solution d'IA capable de personnaliser la planification de séjours pour ses clients. L'ambition couvre quatre axes principaux :

- Des recommandations de destinations adaptées au profil du voyageur (budget, centres d'intérêt, saison, durée).
- Une planification logistique complète (vols, hôtels, transports locaux).
- Une anticipation automatique des imprévus (annulations, météo, perturbations transport).
- Une amélioration continue des propositions grâce aux retours clients.

Le candidat doit concevoir une solution IA fiable, documentée, industrialisable et centrée sur la satisfaction client. La solution doit être conçue selon une démarche scientifique rigoureuse, de l'exploration des données jusqu'au déploiement et au suivi en production.

2. Données du projet — Dataset de voyages

Le fichier fourni `travel_planning_dataset.csv` contient environ 1500 enregistrements représentant des séjours passés, avec leurs contraintes, budgets, profils voyageurs et résultats obtenus.

2.1 Description des colonnes

- **trip_id** : Identifiant unique du séjour
- **client_type** : Famille, couple, solo, business, senior
- **budget_total** : Budget global (€)
- **destination** : Ville / pays
- **saison** : Hiver, printemps, été, automne
- **duree_jours** : Durée totale du séjour (jours)
- **type_hebergement** : Hôtel, resort, appartement, villa
- **prix_vol** : Coût du vol aller-retour (€)
- **meteo_prevue** : Ensoleillé, nuageux, pluie, variable
- **activite_principale** : Plage, randonnée, gastronomie, culture, business
- **satisfaction_client** : Score de satisfaction (1 à 5)
- **imprevus** : Aucun, météo, retard_vol, annulation, bagages
- **reorganisation_necessaire** : Indicateur binaire (0/1)
- **respect_budget** : Indicateur binaire (0/1)
- **retour_client** : Avis court en texte libre

2.2 Droits sur les données

Le dataset fourni est un jeu de données synthétique et anonymisé, utilisable librement dans le cadre de cette certification. Le candidat peut l'enrichir, le filtrer ou le transformer, à condition de documenter chaque modification et d'en justifier la pertinence au regard du besoin métier.

[i] Extension possible (option) : le candidat peut proposer de compléter le dataset avec des sources externes (API météo, plateformes d'avis, données tarifaires) sous réserve de respecter les exigences RGPD & Réglementation, et de documenter les sources.

3. Compétences couvertes et attendus par compétence

Chaque compétence du référentiel doit être explicitement adressée dans le livrable. Le tableau ci-dessous précise, pour chaque compétence, ce qui est attendu dans le cadre de ce cas d'usage.

C1 — Identifier le jeu de données

Exemples d'attendus :

- Produire une datasheet du dataset fourni : description des colonnes, types, volumétrie, sources potentielles (réservations, avis clients, météo, plateformes tierces).
- Identifier les biais potentiels : surreprésentation de certains profils clients, saisonnalité, destinations sur-représentées.
- Évaluer la pertinence et la cohérence des données vis-à-vis du besoin métier (recommandation personnalisée, prévention des imprévus).
- Identifier les données manquantes ou insuffisantes et proposer une stratégie d'enrichissement documentée.

C2 — Risques éthiques et réglementaire

Exemples d'attendus :

- Identifier les risques de biais algorithmiques (discrimination tarifaire, biais culturels dans les recommandations...).
- Analyser les obligations RGPD applicables : données personnelles des clients, durées de conservation, droits des personnes...
- Référencer les cadres réglementaires pertinents : AI Act européen, RGPD, recommandations CNIL...
- Proposer des mesures concrètes de mitigation : anonymisation, minimisation, audit de biais, validation humaine.
- Évaluer l'impact sociétal de la solution : risques de sur-tourisme, homogénéisation des recommandations...

C3 — Préparer les données

Exemples d'attendus :

- Nettoyage : gestion des valeurs manquantes (imputation ou suppression argumentée), détection et traitement des outliers.
- Normalisation et encodage des variables catégorielles.
- Feature engineering : création de nouvelles variables pertinentes (coût_par_jour, ratio_vol_budget, score_risque_imprévu...).
- Analyse des corrélations et sélection de features.
- Constitution d'un Gold Dataset prêt pour l'entraînement, versionné et documenté.

C4 — Choisir le modèle IA

Exemples d'attendus :

- Formuler le(s) problème(s) ML : classification (satisfaction élevée/faible ?), régression (prédiction du score de satisfaction ?), clustering (segmentation clients ?).
- Comparer au moins deux algorithmes en justifiant les choix selon le volume de données et la nature du problème.
- Documenter la démarche de sélection : métriques, artefacts, comparaison de runs...
- Produire une analyse d'explicabilité pour justifier les prédictions auprès du métier.

C5 — Entraîner le modèle

Exemples d'attendus :

- Mettre en place un pipeline d'entraînement structuré avec séparation train/test justifiée.
- Logger automatiquement les métriques et artefacts dans MLflow.
- Optimiser les hyperparamètres en documentant les itérations.
- Analyser les métriques adaptées au problème.

- Évaluer l'impact écologique de l'entraînement.

C6 — Implémenter la solution

Exemples d'attendus :

- Refactorer le code notebook en modules Python réutilisables.
- Exposer le modèle avec documentation.
- Conteneuriser la solution.
- Mettre en place un pipeline d'orchestration couvrant : ingestion → prédiction → stockage des résultats.
- Versionner les données et modèles.

C7 — Architecture cible

Exemples d'attendus :

- Produire un schéma d'architecture cible de la solution (diagramme commenté : sources de données, API, stockage, monitoring...).
- Identifier les contraintes techniques : volumétrie, temps de réponse, disponibilité, sécurité.
- Justifier les choix technologiques au regard des contraintes identifiées.
- Documenter les interfaces entre composants.

C8 — Mesurer la performance

Exemples d'attendus :

- Définir les indicateurs métier de la solution en production : taux de satisfaction client, taux de rebooking, taux de réduction des annulations, respect des budgets.
- Instrumenter l'API et créer un tableau de bord de monitoring
- Mettre en place une détection du data drift sur les données d'entrée.
- Réaliser un test de charge simulant un pic de requêtes et analyser la robustesse de la solution.
- Calculer un ROI simplifié de la solution (gain estimé vs coût de développement / fonctionnement).

C9 — Amélioration continue

Exemples d'attendus :

- Définir un scénario de réentraînement automatique déclenché par dérive des données ou dégradation des métriques.
- Mettre en place un pipeline automatisé de mise à jour du modèle (validation du nouveau modèle avant promotion).
- Produire une documentation technique exhaustive et automatisée.
- Rédiger une rétrospective critique : ce qui fonctionne, ce qui peut être amélioré, les pistes d'évolution (nouvelles sources de données, nouvelles fonctionnalités).

 *Option valorisée : Option : le candidat peut explorer l'intégration d'un composant NLP pour l'analyse automatique des retours clients (sentiment analysis, extraction de thématiques) ou d'un LLM pour la génération de propositions de séjour en langage naturel. Ces options sont valorisées mais non obligatoires.*

4. Latitudes offertes aux candidats

Le cas d'usage définit un cadre, pas un carcan. Les candidats disposent des latitudes suivantes :

- Choix des algorithmes : tout algorithme pertinent et argumenté est acceptable, au-delà des suggestions indicatives.
- Enrichissement du dataset : le candidat peut intégrer des données externes (API publiques, données synthétiques supplémentaires) sous réserve de documentation et de conformité RGPD.
- Périmètre fonctionnel : le candidat peut restreindre ou élargir le périmètre (ex : se concentrer sur la prédiction de satisfaction plutôt que sur la recommandation complète), à

condition de l'expliciter en introduction.

[i] Option valorisée : NLP avancé, IA Générative, Vision par ordinateur : leur utilisation est bienvenue et valorisée à condition qu'ils s'inscrivent logiquement dans la solution. Ils ne constituent pas un attendu obligatoire.

5. Livrables obligatoires

Les livrables suivants sont exigés pour la validation de la certification :

5.1 Notebook certifiant (.ipynb)

Structure minimale attendue :

- Introduction : contexte, périmètre choisi, reformulation du problème ML...
- C1 — Datasheet et analyse exploratoire des données.
- C2 — Analyse éthique et réglementaire documentée.
- C3 — Pipeline de préparation des données avec justifications.
- C4 — Comparaison et sélection du modèle avec démarche scientifique.
- C5 — Entraînement, optimisation et validation du modèle.
- C6 — Implémentation (API, conteneurisation, orchestration).
- C7 — Schéma d'architecture commenté.
- C8 — Monitoring, métriques de performance et test de charge.
- C9 — Stratégie de réentraînement et documentation automatisée.
- Journal de bord : choix techniques, itérations, erreurs rencontrées, arbitrages...

5.2 Dataset utilisé

Le fichier `travel_planning_dataset.csv` fourni, éventuellement enrichi ou transformé. Toute modification doit être tracée et justifiée dans le notebook.

5.3 Support de soutenance (PDF ou PPTX)

Le support doit couvrir :

- Présentation du contexte et du problème métier.
- Architecture de la solution.
- Démonstration des résultats (métriques, tableau de bord de monitoring).
- Analyse critique et pistes d'amélioration.
- Positionnement éthique et réglementaire.

5.4 Soutenance orale

La soutenance comprend :

- Présentation de la solution opérationnelle et conteneurisée (démonstration live si possible).
- Argumentation des choix techniques et éthiques.
- Réponses aux questions du jury sur l'ensemble des compétences C1 à C9.

6. Critères d'évaluation

Chaque compétence est évaluée selon trois axes :

- Maîtrise technique : pertinence et qualité d'implémentation.
- Démarche scientifique : rigueur, justification des choix, analyse critique des résultats.
- Qualité de communication : clarté de la documentation, du notebook et du support de soutenance.

Les options valorisée : NLP, IA Générative, sources externes peuvent permettre d'atteindre le niveau d'excellence, mais leur absence ne pénalise pas le candidat si toutes les compétences obligatoires sont couvertes.